

ORACLE

OCI Search Service with OpenSearch ご紹介

Name

日本オラクル株式会社

2025年5月



全文検索とは


- 複数の文書の中から目的の文字列を検索すること
- 全文検索の手法
 - grep 型（逐次検索型）
 - 複数文書の内容を順次走査する検索手法のこと
 - 検索対象の増加に伴い、検索速度が低下する
 - 索引（インデックス）型
 - 検索対象となる文書群を走査し、高速な検索が可能になるような索引データを準備することで、検索時のパフォーマンスを向上させる手法のこと
 - インデクシング：事前に索引ファイルを作成すること
 - インデックス：インデクシングにより生成されるデータのこと（文字列、ファイルの場所、更新日、出現頻度、etc.）

OpenSearch

<https://opensearch.org/>

OpenSearch makes it easy to ingest, search, visualize, and analyze your data.

- OpenSearch
 - オープンソースの検索、分析スイート
 - 索引型の全文検索エンジンを提供
 - データの取り込み、検索、可視化、分析をAPIやWeb UIを通して実行可能
 - Apache Licence, Version 2.0で提供
 - Elasticsearch 7.10.2とKibana 7.10.2から派生し、コミュニティドリブンで開発
 - 主なユースケース
 - ログの分析
 - アプリケーションモニタリング
 - 検索ロジックの実装(セマンティック検索含※)
- ※ : v2.11以降





OCI Search Service with OpenSearch

■ ユースケース





- ログの分析
- アプリケーションの検索ロジック実装

■ 特徴

- [OpenSearch](#)ベースのフルマネージドな検索/分析スイート
- コア数/メモリを柔軟にダウンタイムなしで拡張可能
- AD/FDにまたがった高可用性構成を自動的に構築
- 統合済みのダッシュボードを用いて、分析したデータを素早く可視化
- 既存のクラスター(ELK or OpenSearch)からのマイグレートが可能
- OCI Generative AI Agents(2024/5現在、β版)を利用したチャットボット実装が可能(v2.3以降)

■ 価格

- 3 台目のData Node以降、1 ノードあたり\38.75/h
- ※OCI Search Service with OpenSearchを稼働させるIaaS(Compute, Block Volume)使用料が別途発生



OCI Search Service with OpenSearch のメリット

フルマネージド



- コンソールや API から自動的にクラスタ構築
- 定期的な自動バックアップ
- 自動的なパッチ適用

柔軟性



- コア数・メモリ数を柔軟にスケール可能
- ダウンタイムなしで拡張可能

セキュア



- OCI IAM との統合によるアクセス制御と認可を実現
- すべてのデータは暗号化して保存される
- FIPS準拠

コスト



- 最初の 2 データノードまでは無償*で使用可能
- 運用コストの削減

*: IaaSの使用料は発生

可視化機能



- 統合済みのダッシュボードを用いて、データを素早く可視化
- オンプレミス、クラウド両方のデータ取り込みが可能

高可用性



- AD/FD にまたがった分散配置を自動的にプロビジョニング

OCI Search Service with OpenSearch の全体像

Cluster

- 1 つ以上の Master/OpenSearch Dashboard/Data Node から構成される Computeインスタンスの集合

Master Node


- クラスタのオペレーション管理、ノードのステータス監視、ネットワークトラフィックの制御を行う管理ノード

OpenSearch Dashboard Node


- クラスタの OpenSearch ダッシュボードを管理するノード

Data Node

- OpenSearch のデータを保存し、データの検索、管理、集計に関連する操作を処理するノード



価格モデル




※ 3 ノード以上で Data Node を構成する場合は、3 ノード目以降から**ノード毎に Service Fee が発生**
e.g. 5 ノードの場合: 5-2=3 ノードに Service Fee が発生




ユースケース: ログ分析

- 使い慣れた OpenSearch の Web UI を用いてログの分析が可能
- アプリケーションサーバーのログなどOCIサービスではないログ分析に特に有効的



ダッシュボードの構築



膨大なログデータの中から迅速に目的のログを検索

*SCH: Service Connector Hub



参考: OCI Logging Analytics との使い分け

	Search Service w/ OpenSearch		Logging Analytics	
対象のログ	監査ログ	○	監査ログ	◎
	サービス・ログ	○	サービス・ログ	◎
	カスタム・ログ	◎	カスタム・ログ	○
コスト（最小構成）[月額]	\15,847		\52,080	

※2024年5月現在


【OCI Search Service with OpenSearchがログ分析で有効活用できるケース】

- 顧客独自のアプリケーションなどが出力する**カスタム・ログに対する検索や分析を実施したい場合**
 - OCI Logging Analyticsは、OCI Nativeなログに最適化されている
- 使い慣れたOpenSearchのUIを用いて、分析を実施したい場合
- 検索性能のスケールが要件に含まれている場合
- スモールスタートでログ分析を始めたい場合



ユースケース: 検索ロジックの実装

- アプリケーションの検索ロジック（論理演算(AND, OR, etc.)を用いた検索、類似語検索、etc.）を OpenSearch の API を用いて実装
- 大量データから目的のデータへの高速アクセスを提供



見積り例（2024年5月現在） – 開発、検証用途のクラスタ環境の場合

Master Node x 1, Dashboard Node x 1, Data Node x 1

サービス名/リソース名	構成の概要	見積りの概要	月額
Compute x 1 (Master Node)	1OCPU, 20GB RAM	$\backslash 3.875 \times 1(\text{OCPU}) \times 24(\text{h}) \times 31(\text{day}) \times 1(\text{台}) = \backslash 2,883$ $\backslash 0.2325 \times 20(\text{GB}) \times 24(\text{h}) \times 31(\text{day}) \times 1(\text{台}) = \backslash 3,460$	\6,343
Compute x 1 (Dashboard)	1OCPU, 8GB RAM	$\backslash 3.875 \times 1(\text{OCPU}) \times 24(\text{h}) \times 31(\text{day}) \times 1(\text{台}) = \backslash 2,883$ $\backslash 0.2325 \times 8(\text{GB}) \times 24(\text{h}) \times 31(\text{day}) \times 1(\text{台}) = \backslash 1,384$	\4,267
Compute x 1 (Data Node)	1OCPU, 20GB RAM	$\backslash 3.875 \times 1(\text{OCPU}) \times 24(\text{h}) \times 31(\text{day}) \times 1(\text{台}) = \backslash 2,883$ $\backslash 0.2325 \times 20(\text{GB}) \times 24(\text{h}) \times 31(\text{day}) \times 1(\text{台}) = \backslash 3,497$	\6,380
Block Storage (Data Node)	50GB	$\backslash 3.9525 \times 50(\text{GB}) \times 1(\text{台}) + \backslash 0.2635 \times 10(\text{VPU}) \times 50(\text{GB}) \times 1(\text{台}) = \backslash 329$	\329
Service Fee*		-	-
		合計 [月額]	\17,319

*: 3 ノード以上で Data Node を構成する場合は、3 ノード目以降からノード毎に Service Fee が発生



見積り例（2024年5月現在） – 本番相当のクラスタ環境の場合 (Log Analytics)

Master Node x 3, Dashboard Node x 3, Data Node x 3

サービス名/リソース名	構成の概要	見積りの概要	月額
Compute x 3 (Master Node)	20CPU, 32GB RAM	$\backslash 3.875 \times 2(\text{OCPU}) \times 24(\text{h}) \times 31(\text{day}) \times 3(\text{台}) = \backslash 17,298$ $\backslash 0.2325 \times 32(\text{GB}) \times 24(\text{h}) \times 31(\text{day}) \times 3(\text{台}) = \backslash 16,606$	\33,904
Compute x 3 (Dashboard)	20CPU, 16GB RAM	$\backslash 3.875 \times 2(\text{OCPU}) \times 24(\text{h}) \times 31(\text{day}) \times 3(\text{台}) = \backslash 17,298$ $\backslash 0.2325 \times 16(\text{GB}) \times 24(\text{h}) \times 31(\text{day}) \times 3(\text{台}) = \backslash 8,303$	\25,601
Compute x 3 (Data Node)	320CPU, 244GB RAM	$\backslash 3.875 \times 32(\text{OCPU}) \times 24(\text{h}) \times 31(\text{day}) \times 3(\text{台}) = \backslash 276,768$ $\backslash 0.2325 \times 244(\text{GB}) \times 24(\text{h}) \times 31(\text{day}) \times 3(\text{台}) = \backslash 126,621$	\403,389
Block Storage (Data Node)	50GB	$\backslash 3.9525 \times 50(\text{GB}) \times 3(\text{台}) + \backslash 0.2635 \times 10(\text{VPU}) \times 50(\text{GB}) \times 3(\text{台}) = \backslash 988$	\988
Service Fee*		$\backslash 38.75 \times 24(\text{h}) \times 31(\text{day}) \times 1(\text{台}) = \backslash 28,830$	\28,830
		合計 [月額]	\492,712

*: 3 ノード以上で Data Node を構成する場合は、3 ノード目以降からノード毎に Service Fee が発生



見積り例（2024年5月現在） – 本番相当のクラスタ環境の場合


Master Node x 3, Dashboard Node x 3, Data Node x 3

サービス名/リソース名	構成の概要	見積りの概要	月額
Compute x 3 (Master Node)	20CPU, 32GB RAM	$\backslash 3.875 \times 2(\text{OCPU}) \times 24(\text{h}) \times 31(\text{day}) \times 3(\text{台}) = \backslash 17,298$ $\backslash 0.2325 \times 32(\text{GB}) \times 24(\text{h}) \times 31(\text{day}) \times 3(\text{台}) = \backslash 16,606$	\33,904
Compute x 3 (Dashboard)	20CPU, 16GB RAM	$\backslash 3.875 \times 2(\text{OCPU}) \times 24(\text{h}) \times 31(\text{day}) \times 3(\text{台}) = \backslash 17,298$ $\backslash 0.2325 \times 16(\text{GB}) \times 24(\text{h}) \times 31(\text{day}) \times 3(\text{台}) = \backslash 8,303$	\25,601
Compute x 3 (Data Node)	64OCPU, 244GB RAM	$\backslash 3.875 \times 64(\text{OCPU}) \times 24(\text{h}) \times 31(\text{day}) \times 3(\text{台}) = \backslash 553,536$ $\backslash 0.2325 \times 244(\text{GB}) \times 24(\text{h}) \times 31(\text{day}) \times 3(\text{台}) = \backslash 126,621$	\680,157
Block Storage (Data Node)	50GB	$\backslash 3.9525 \times 50(\text{GB}) \times 3(\text{台}) + \backslash 0.2635 \times 10(\text{VPU}) \times 50(\text{GB}) \times 3(\text{台}) = \backslash 988$	\988
Service Fee*		$\backslash 38.75 \times 24(\text{h}) \times 31(\text{day}) \times 1(\text{台}) = \backslash 28,830$	\28,830
		合計 [月額]	\769,480

*: 3 ノード以上で Data Node を構成する場合は、3 ノード目以降からノード毎に Service Fee が発生




Reference Architecture – Log Analysis



<https://docs.oracle.com/en/solutions/oci-opensearch-log-analytics/index.html#GUID-AE21AAA4-FA48-4EA9-A80D-A3199AC9AEA6>



Reference Architecture – App Search



<https://docs.oracle.com/en/solutions/oci-opensearch-application-search/index.html#GUID-AEAA600E-BBCC-4102-8E23-ABEC941FE84C>



Thank you



ORACLE

Appendix(AI関連機能)

v2.15以降で利用可能なAI関連機能 – 事前統合済みモデル –

事前統合済みモデル

- Hugging Faceで公開されているSentence-Transformersモデル（文章をベクトルに変換するモデル）が複数統合されており、モデルの即時デプロイと利用が可能
 - デプロイ後にPredict APIによって利用可能


モデル名	バージョン	ベクトル寸法	自動切替	スクリプト形式
huggingface/sentence-transformers/all-distilroberta-v1	1.0.1	768次元密度ベクトル空間	はい	TORCH_SCRIPT ONNX
huggingface/sentence-transformers/all-MiniLM-L6-v2	1.0.1	384次元密度ベクトル空間	はい	TORCH_SCRIPT ONNX
huggingface/sentence-transformers/all-MiniLM-L12-v2	1.0.1	384次元密度ベクトル空間	はい	TORCH_SCRIPT ONNX
huggingface/sentence-transformers/all-mpnet-base-v2	1.0.1	768次元密度ベクトル空間	はい	TORCH_SCRIPT ONNX
huggingface/sentence-transformers/msmarco-distilbert-base-tas-b	1.0.2	768次元密度ベクトル空間セマンティック検索用に最適化されています。	はい	TORCH_SCRIPT ONNX
huggingface/sentence-transformers/multi-qa-MiniLM-L6-cos-v1	1.0.1	384次元密度ベクトル空間セマンティック検索用に設計され、2億1,500万の質問/回答ペアでトレーニングを受けています。	はい	TORCH_SCRIPT ONNX
huggingface/sentence-transformers/multi-qa-mpnet-base-dot-v1	1.0.1	384次元密度ベクトル空間	はい	TORCH_SCRIPT ONNX
huggingface/sentence-transformers/paraphrase-MiniLM-L3-v2	1.0.1	384次元密度ベクトル空間	はい	TORCH_SCRIPT ONNX
huggingface/sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2	1.0.1	384次元密度ベクトル空間	はい	TORCH_SCRIPT ONNX



v2.11以降で利用可能なAI関連機能 – ニューラル検索 –

ニューラル検索

- OpenSearchが提供するAI検索機能として以下をサポート
 - セマンティック検索（ベクトル検索）
 - ハイブリッド検索（ベクトル検索 + 全文検索）
 - マルチモーダル検索（テキスト + 画像検索）
 - 会話型検索（チャットボットの検索）
- 事前統合済みモデル/外部モデルのいずれも利用可
 - 外部モデルはObject Storageを利用
- OCI Generative AIサービスで提供しているモデルも利用可
 - Generative AIコネクタを利用し、会話型検索で自然言語でのクエリをリクエストし、ハイブリッド検索やBM25（情報検索の手法）での検索が可能



v2.11以降で利用可能なAI関連機能 – RAGパイプライン –

RAGパイプラインの作成

- RAGパイプライン（対象データのEmbeddingとインデックス作成）の自動化をOCI Generative AI Agentsとの連携で実施可能な機能
- OCI Generative AIがホスティングするモデル(Cohere.Command/Meta Llama)を利用したEmbeddingと検索の実行
- 構築はUI（OCIコンソール）で完結
- RAGパイプラインは事前統合済みモデルでも利用可能
 - APIで設定が必要

RAGパイプラインの構成

The screenshot displays the 'RAGパイプラインの構成' (RAG Pipeline Configuration) page in the OCI console. The page is divided into several sections:

- General information:** This section contains input fields for 'パイプライン名' (Pipeline Name), '説明' (Description), 'タグ' (Tag), and 'コンテキスト・フィールド・リスト' (Context Field List). A note states: '検索拡張生成(RAG)パイプラインを作成することで、特定のソースからデータを取得して大規模言語モデル(LLM)のレスポンスを特定の情報で強化し、関連のあるレスポンスを生成します。' (By creating a Retrieval-Augmented Generation (RAG) pipeline, you can retrieve data from specific sources and enhance the response of a large language model (LLM) with specific information to generate relevant responses.)
- クラスター・ポータル 資格証明** (Cluster Portal Authentication): This section includes a 'クラスター・ユーザー名' (Cluster Username) field and a note: 'クラスターでの生成AIコマンドにはシークレットが必要です。ポータルとシークレットを持っていない場合、ポータルとシークレットを作成してください。' (A secret is required for the generative AI command on the cluster. If you do not have the portal and secret, create the portal and secret.) Below this is a dropdown for 'takuya.mitaのポータル (コンパートメントの変更)' (takuya.mita's Portal (Change Compartment)) and a 'コンパートメントの選択' (Select Compartment) button.
- シークレット** (Secret): This section has a '最初ポータルを選択します' (Select initial portal) button and a dropdown for 'シークレット・バージョン' (Secret Version).
- モデル・グループ** (Model Group): This section is partially visible at the bottom of the screenshot.



v2.11以降で利用可能なAI関連機能 – OCI DataScienceとの統合 –

DataScienceコネクタ

- RAGパイプラインにOCI DataScienceで管理しているモデルを利用可能
 - OCI DataScienceではHugging Faceからのモデル持ち込みをサポート
- OCI Generative AIでのRAGパイプラインとは異なり、OpensearchのAPIを利用したCLIベースでの設定が必要

